

雑音・無雑音バイナリ分類器に基づく誤り訂正出力符号化の性能評価



Performance Evaluation of ECOC Based on Noisy and Noiseless Binary Classifiers

雲居 玄道¹, 八木 秀樹², 小林 学³, 後藤 正幸³, 平澤 茂一³

¹長岡技術科学大学 ²電気通信大学 ³早稲田大学



研究背景

多クラス分類問題（クラス数 M ）に対して、誤り訂正出力符号化（ECOC）は n 個のバイナリ分類器の出力を組み合わせる アンサンブル学習の枠組みである。各クラス c_j に符号語 $m_j \in \{-1, +1\}^n$ を割り当てる。




図 1: ECOC の符号行列 ($M = 4, n = 6$ の例)

バイナリ分類器 $h_{k(x)}$ の出力とクラス c_j の符号語を比較し、ハミング距離が最小のクラスに分類する。

問題意識: バイナリ分類器が確率スコア $\Pr\{c_i | \tilde{x}\}$ を出力する場合、確率スコアを直接利用した最適デコーディングの理論的性能評価が未解決であった。

提案手法

確率的デコーディングの定式化

バイナリ分類器の出力を確率スコア $\Pr\{c_i | \tilde{x}_i\}$ でモデル化し、評価関数（対数尤度比）を定義する：

$$r(c_i, c_k | \tilde{x}_i) = \log \frac{\Pr\{c_i | \tilde{x}_i\}}{\Pr\{c_k | \tilde{x}_i\}}$$

分類則:

$$\hat{c} = \arg \max_j \sum_{k=1}^n r(c_j^k | \tilde{x}_k)$$

ガウス雑音 $\eta \sim \mathcal{N}(0, \sigma^2 I)$ のモデルを仮定： $\tilde{x} = x + \eta$




図 2: 評価関数 $r(c_i, c_k | \tilde{x}_i)$ の特性 ($M = 8$, 各コード設計)

r は確率スコアの単調増加関数であり、 $d_{\min}$ が大きいほど誤り耐性が高い。

実験設定

データセット

- 20 Newsgroups : 20 クラス文書分類, 18,846 件
- バイナリ分類器 : Logistic Regression (LR), DNN
- 評価指標 : AUC (Area Under Curve)

ECOC コード設計の比較 ($M = 8$ クラス)

符号設計	符号長 n	最小距離 $d_{\min}$
1-vs-Rest	8	2
2-vs-Rest	56	12
3-vs-Rest	168	30
Exhaustive	128	64

実験パラメータ： $\sigma^2 = 5.80$ （最大雑音強度）を採用。全コード設計で 10 回クロスバリデーションを実施した。

実験結果

20 Newsgroups での実験結果 (Logistic Regression)




図 3: AUC の比較 (LR, 20 クラス, 95% 信頼区間)

- Exhaustive ($d_{\min} = 64$) が全条件で最高 AUC を達成
- $d_{\min}$ の増加とともに AUC が単調改善
- 提案の確率的デコーディングはハミング復号より AUC を最大 +2.3 pt 向上

主要結果: $d_{\min}$ を大きくするほど高精度——理論解析と実験が一致。

まとめ & 今後の課題

まとめ

- ECOC の確率的デコーディングを理論的に定式化し、ガウス雑音下での誤り確率の上界を導出した。
- 最小ハミング距離 $d_{\min}$ が大きいコード設計ほど誤り確率が低下することを理論・実験の両面から確認した。
- 20 Newsgroups ($M = 20$) での実験により Exhaustive コードの優位性を実証した。

今後の課題

- 非ガウス雑音モデルへの拡張（ラプラス分布、混合ガウス）
- 最適コード設計の自動探索アルゴリズム
- 大規模多クラス問題 ($M > 100$) への適用





図 4: AUC vs. 雑音強度 σ^2 ($M = 8$, LR)



研究室サイト
<https://tml.nagaokaut.ac.jp>

Paper DOI:
10.1142/
S0129065723500156